

Segunda sesión

Fundamentos Cloud







Resumen del curso

Plan de Estudios de Google Cloud Platform (GCP)

Bloque 2: Fundamentos Cloud

Fundamentos de Arquitectura Cloud

Principios de diseño de arquitecturas resilientes, escalables y de alta disponibilidad en la nube Patrones de diseño comunes en la nube (microservicios, serverless, contenedores)

AWS

Visión general de los servicios principales de AWS (EC2, S3, Lambda, RDS)

Google Cloud Platform

Servicios fundamentales de GCP: Compute Engine (máquinas virtuales), Cloud Storage (almacenamiento de objetos), VPC (redes virtuales), Cloud SQL (bases de datos gestionadas)







Resumen del curso

Plan de Estudios de Google Cloud Platform (GCP)

Bloque 2: Fundamentos Cloud

Google Cloud Platform

Servicios fundamentales de GCP: Compute Engine (máquinas virtuales), Cloud Storage (almacenamiento de objetos), VPC (redes virtuales), Cloud SQL (bases de datos gestionadas). Gestión de recursos en GCP: proyectos, facturación, IAM (Identity and Access Management)

Azure

Visión general de los servicios principales de Azure (Virtual Machines, Blob Storage, Azure Functions, Azure SQL Database)







Ventajas y desventajas Cloud (Recapitulación)

Escalabilidad
Alta disponibilidad
Costo eficiente *
Seguridad robusta
Velocidad de despliegue

Dependencia del proveedor

*Seguridad compartida

*Costos impredecibles

Implementaciones no
regulares







Ventajas y desventajas Cloud (Recapitulación)

Escalabilidad
Alta disponibilidad
Resiliente















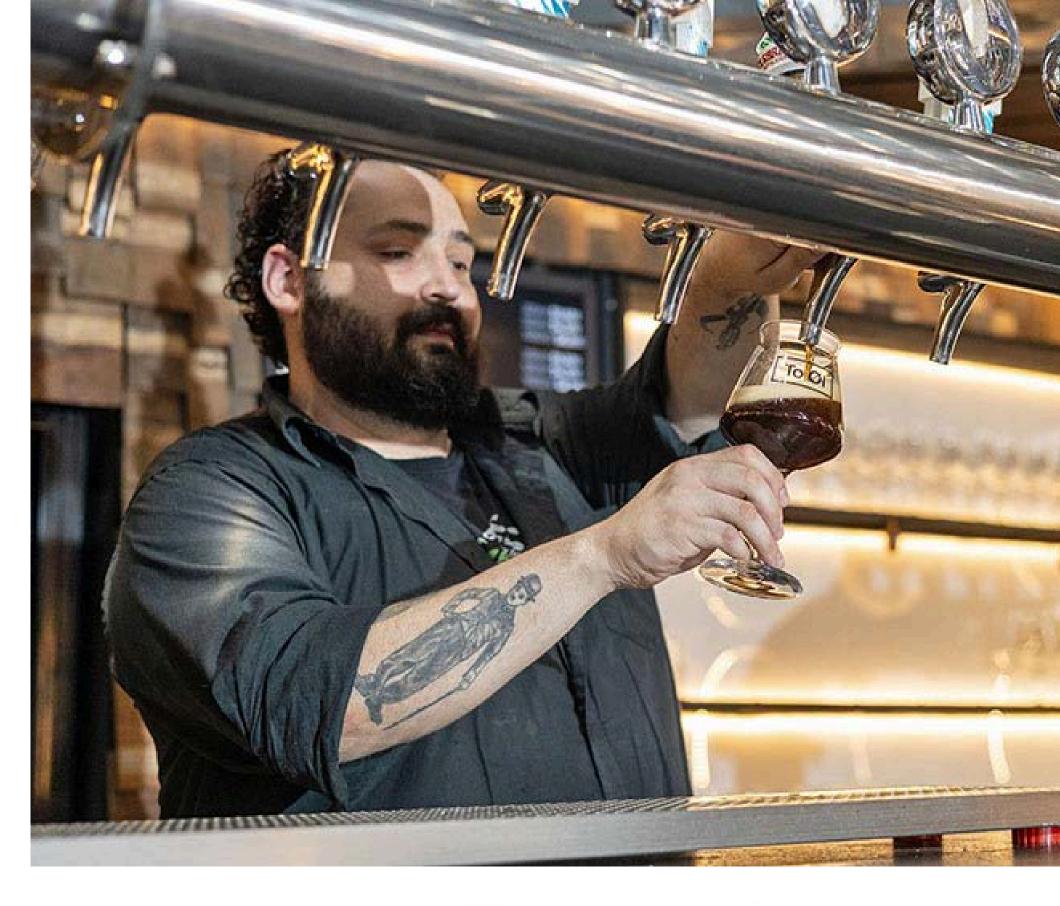
Soy dueño de un bar y mis clientes no paran de crecer

El problema:

Al principio, en mi bar venían grupos pequeños. Una mesa para 4 personas era suficiente. Pero ahora, cada semana vienen más y más personas en grupos más grandes: de 6, de 8, de 10.

Tengo que pensar cómo adaptar mi espacio para atender a más gente sin que se vayan a otro lugar.

¿Qué opciones tengo?

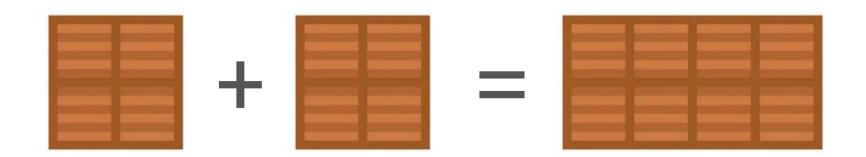








Opción 1 (Horizontal)

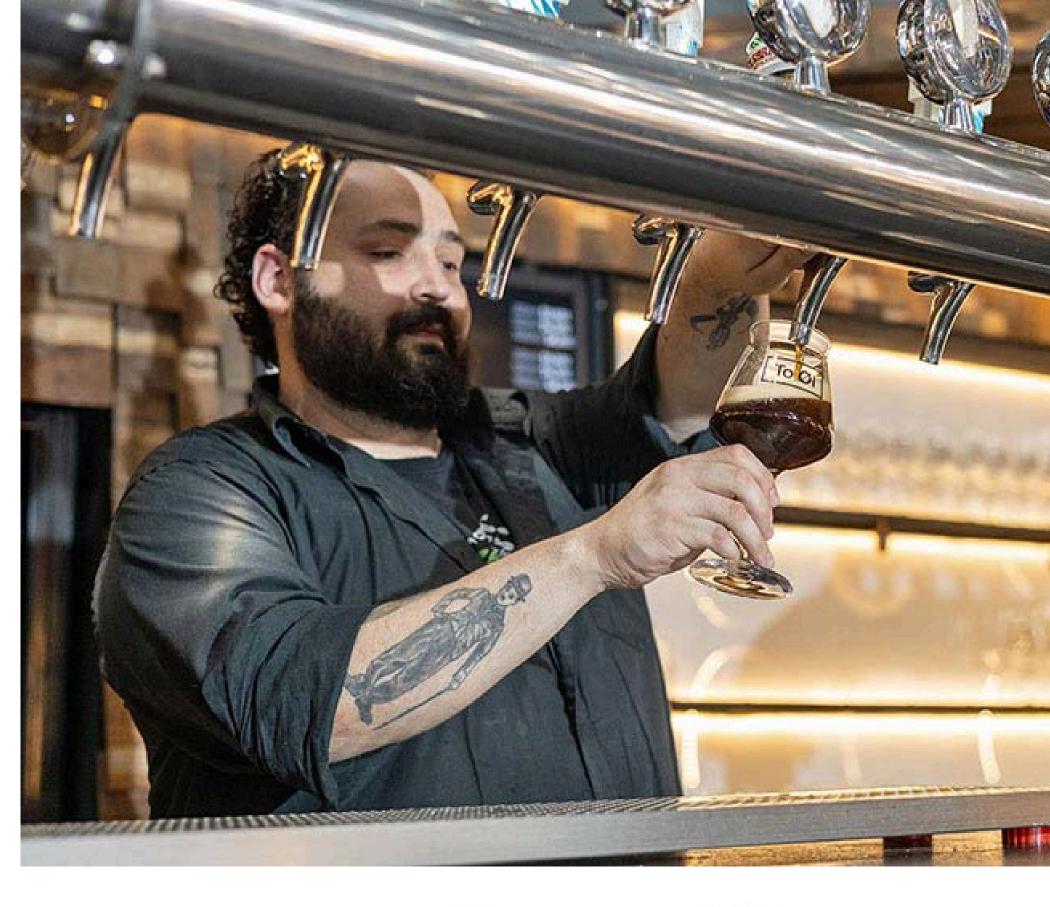


Juntar mesas pequeñas

¿Por qué sirve?

Puedo atender cualquier número de personas y distribuir las mesas

Puedo utilizar mesas pequeñas que ya tengo

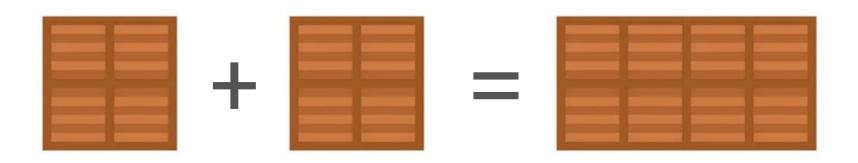








Opción 1 (Horizontal)



¿Dificultades?

Necesito cambiar distribuciones, y coordinar al personal

Podrían considerarlas pequeñas para la celebración

La distribución podría no ser ideal



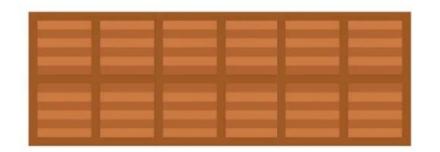






Valor centrado en el desarrollo de las personas

Opción 2 (Vertical)



Mesas más grandes

¿Por qué sirve?

Tiene más capacidad para atender más gente

Es más fácil de implementar

Logistica más simple

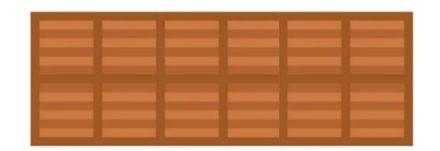








Opción 2 (Vertical)



Mesas más grandes

¿Dificultades?

No puedo atender más personas que los que permite la mesa

Son más costosas

Muchas mesas quedarán con asientos vacios

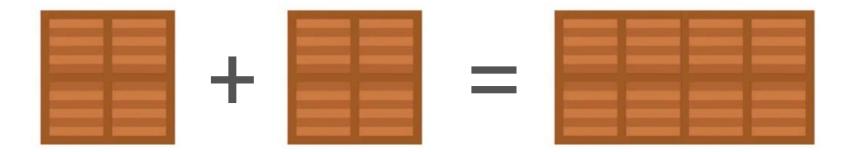






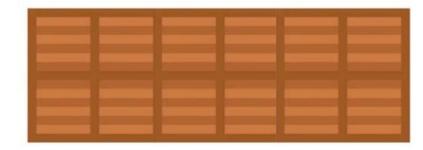


Opción 1 (Horizontal)



U

Opción 2 (Vertical)



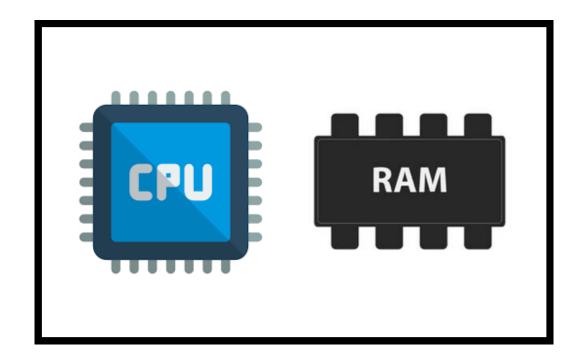




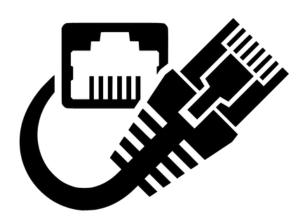




¿Y en la nube?







¿Qué conceptos importantes considerar?

Stateless y Event Driven Load Balancers Autoscaling

¿Qué nos podría ayudar a mejorar rendimiento?

Caché Sharding / Partitioning

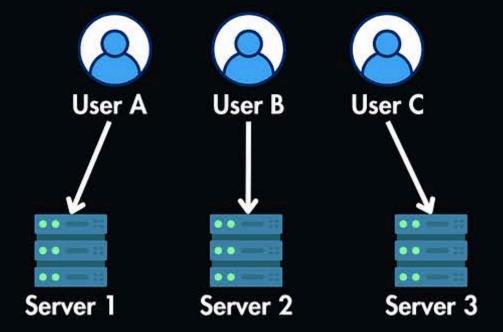






Wrap Up



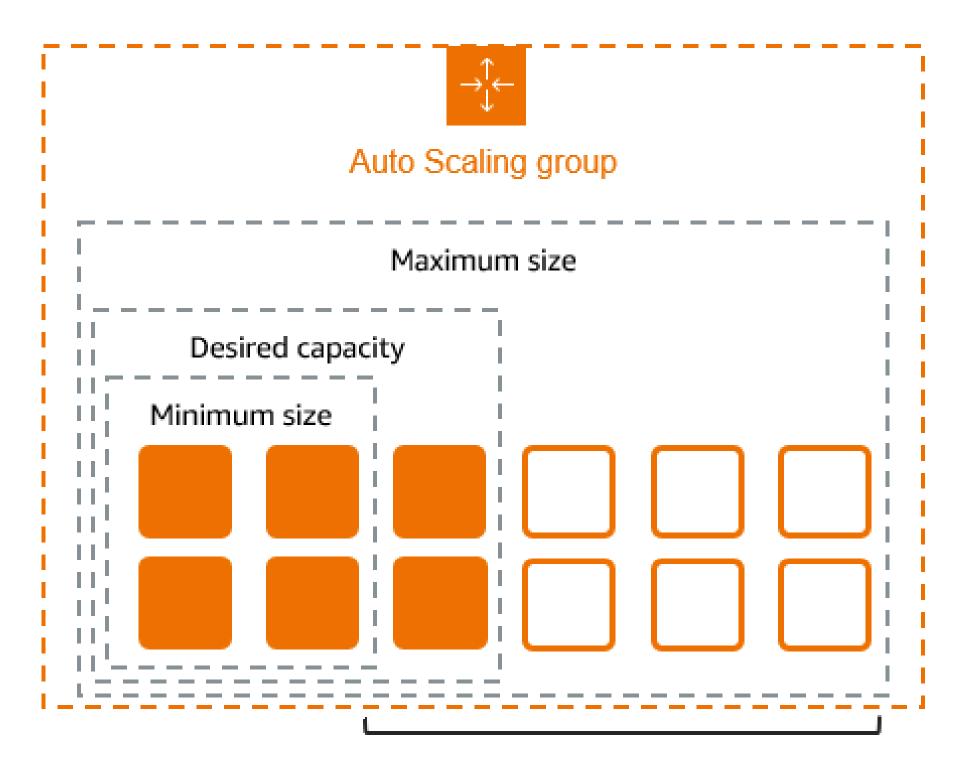










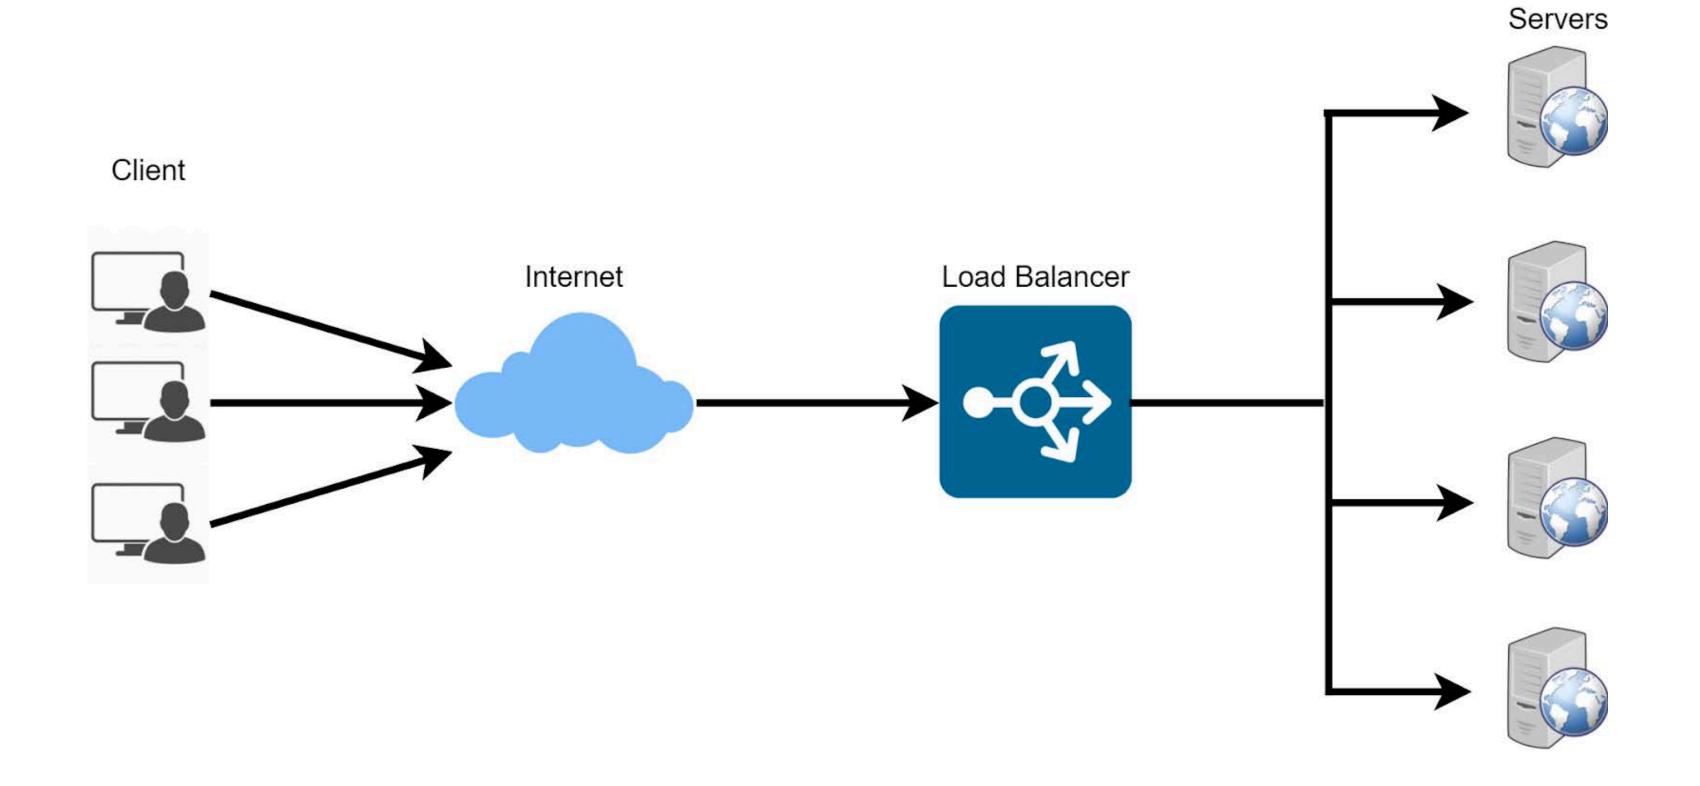


Scale between min and max







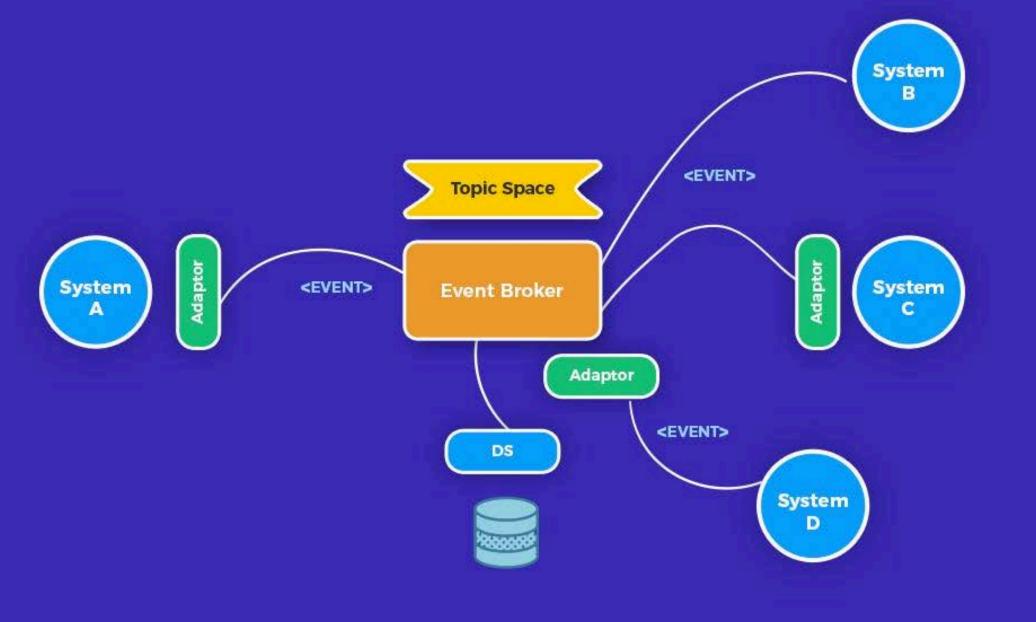








EVENT DRIVEN ARCHITECTURE









Caso Práctico

Una empresa de tecnología financiera (fintech) opera una plataforma de pagos online similar a Mercado Pago. Los usuarios realizan transacciones en tiempo real desde múltiples canales (web, app, API de terceros).

En los últimos meses, el sistema de procesamiento de transacciones ha experimentado cuellos de botella, especialmente en horarios de alta demanda, lo que ha provocado retrasos en la confirmación de pagos y en la visualización de los movimientos por parte de los usuarios.

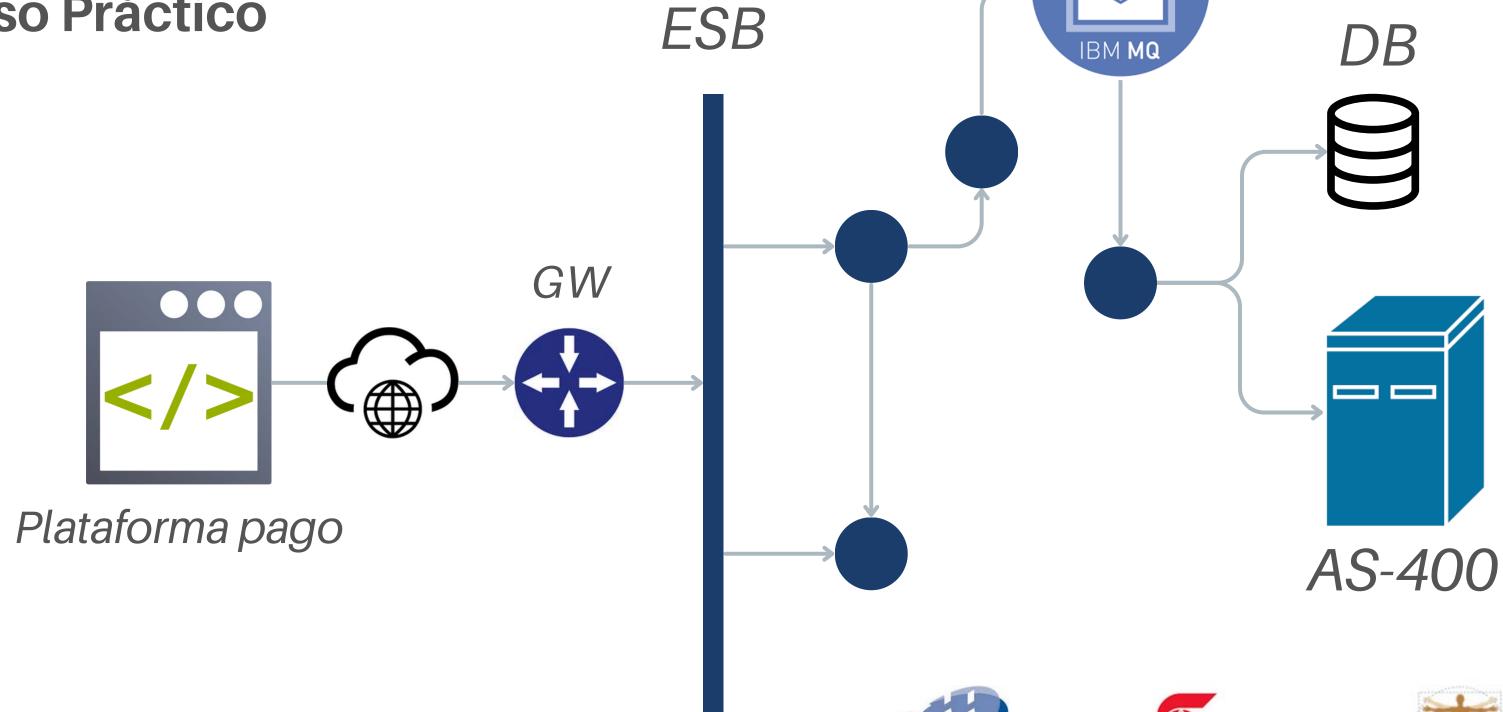
Actualmente, el servicio de carga y validación de transacciones se ejecuta en un servidor centralizado, lo que ha demostrado ser insuficiente frente al crecimiento del volumen de operaciones.







Caso Práctico



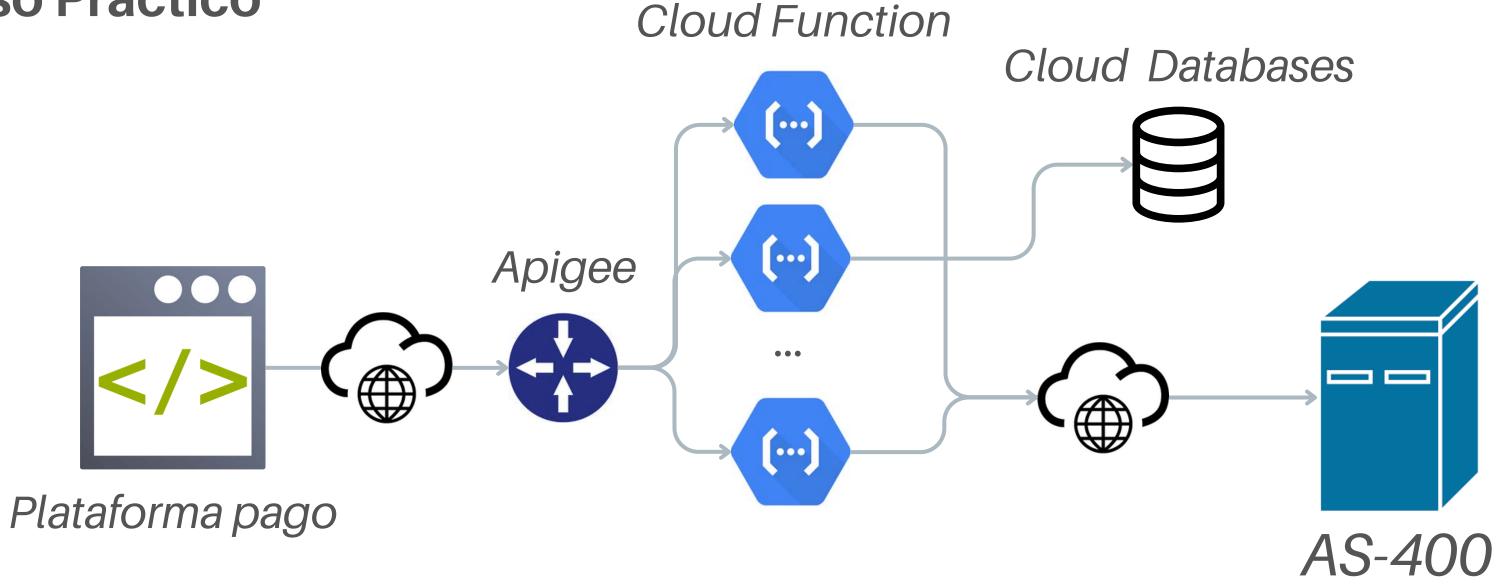


Group

Queue Service



Caso Práctico









Imagina que tienes una reunión muy importante y necesitas llegar sí o sí a tiempo usando Transantiago.

Y se suspende el recorrido de la 506, que es el que te sirve









Sin alta disponibilidad

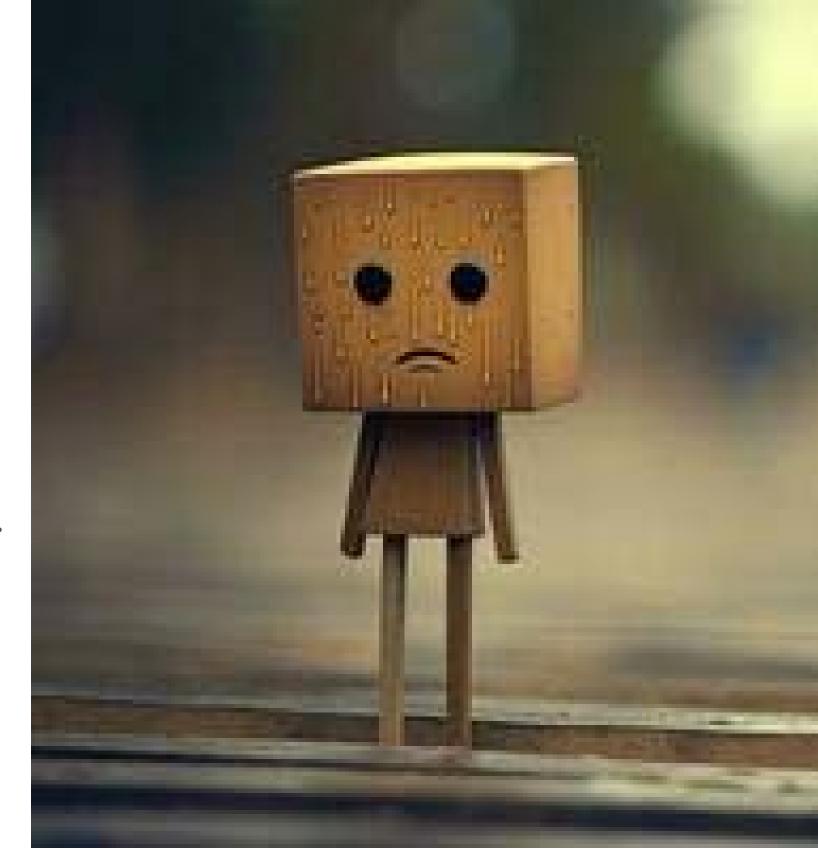
Te acercas a tu paradero y esperas el bus que tomas siempre. Pero ese bus no llega.

Preguntas o revisas en la app, y te dicen:

"Ese recorrido está suspendido por hoy."

No hay buses alternativos cerca, ni otra forma rápida de llegar. Te quedaste sin servicio.

Todo deja de funcionar!!!!









¿Cómo mejoramos la disponibilidad del servicio?

- La app de Transantiago te sugiere otras combinaciones de buses o incluso Metro.
- Si un bus no aparece, puedes tomar otro recorrido alternativo que conecta con tu destino.

Redundancia

- Incluso si hay un desvío en la ruta, el sistema reorganiza las opciones para que no te quedes sin transporte.
- Monitoreo de recorrido y estado de servicios de transporte (tomando acciones rápidas)

Tolerancia a fallos





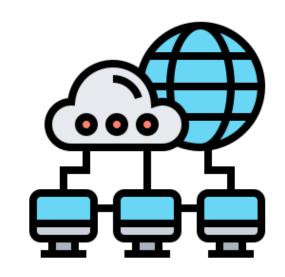


Redundancias



¿Qué normalmente requiere redundancia?





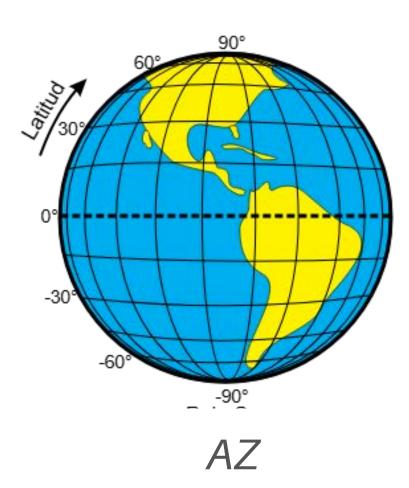








Consideraciones



Posibles desastres naturales
Problemas de conectividad
Cortes de luz
Regulaciones locales



Costo de sistemas



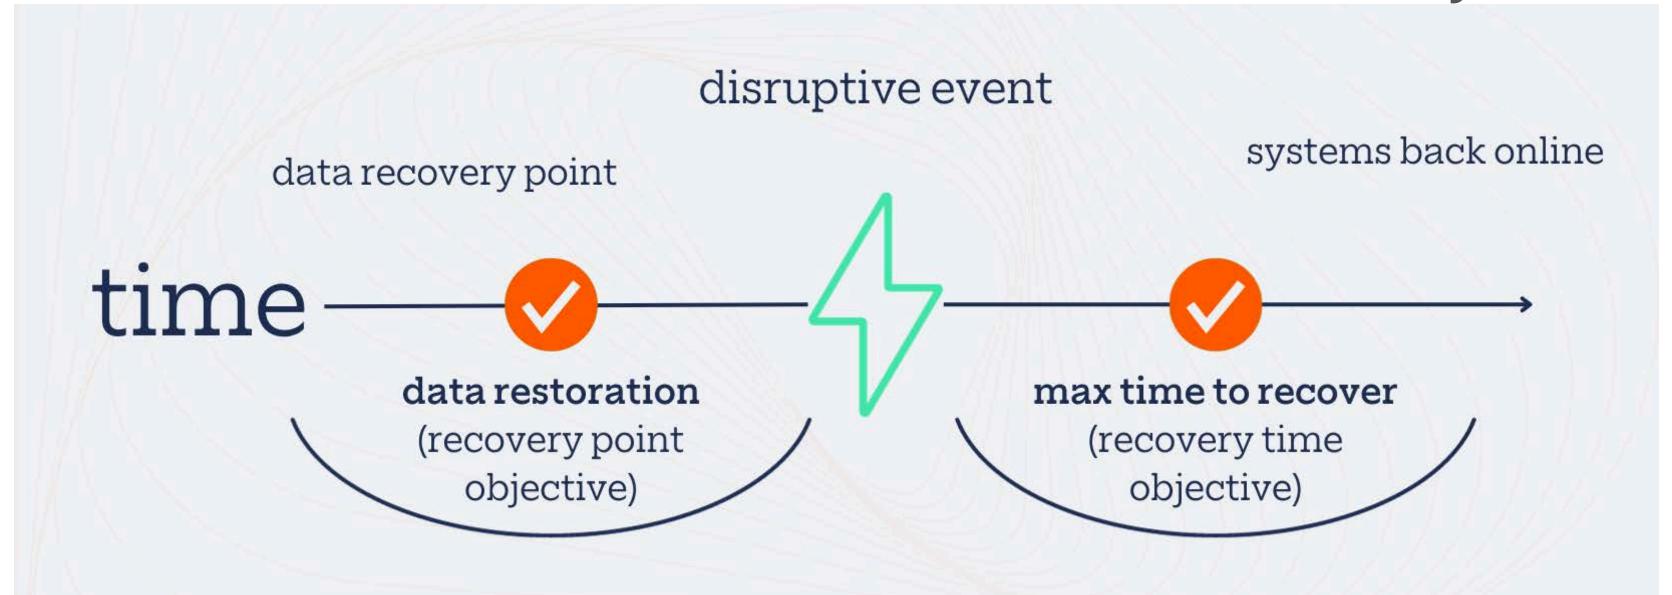






Consideraciones

RPO y RTO









Caso Práctico

El banco quiere lanzar un nuevo servicio digital para sus clientes (por ejemplo, una plataforma para gestionar inversiones). Dado que maneja información sensible y está sujeto a regulaciones, requiere:

Alta disponibilidad

- Continuidad operacional ante fallos
- Cumplimiento con normativas locales (datos sensibles deben estar on-premise)
- Escalabilidad rápida en caso de alta demanda

Objetivo del caso:

 Diseñar una arquitectura de alta disponibilidad híbrida (on-premise + cloud) para este nuevo servicio, que asegure resiliencia, failover automático y cumplimiento.







Caso Práctico

Arquitectura Simplificada de Sandbox (On-Premise)

Elementos:

- 1 servidor Apache
- 1 servidor Spring Boot
- 1 HAProxy como balanceador
- 1 PostgreSQL primario
- 1 Redis para caché
- Switch L3 para redundancia de red







Caso Práctico

¿Cómo añadimos HA?



Flowchart Maker & Online Diagram Software

draw.io is free online diagram software for making flowcharts, process diagrams, org charts, UML, ER...

A diagrams.net







Caso Práctico

¿Cómo sería en la nube?



Flowchart Maker & Online Diagram Software

draw.io is free online diagram software for making flowcharts, process diagrams, org charts, UML, ER...

A diagrams.net







Capacidad de un sistema para tolerar fallos parciales sin afectar su operación global, y recuperarse automáticamente para seguir funcionando con mínima intervención humana.

No sólo disponible, también responder a fallas

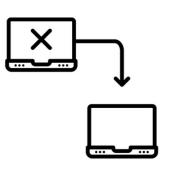




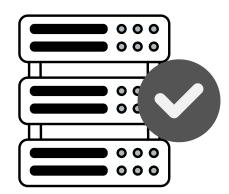




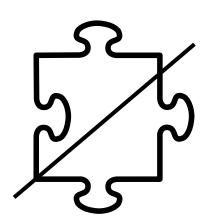
Health checks para detectar problemas en tiempo real.



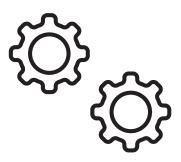
Failover controlado: si una región falla, enrutar a otra (DNS, Route 53).



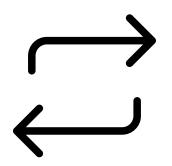
Failover controlado: si una región falla, enrutar a otra (DNS, Route 53).



Circuit breakers: evitan cascadas de fallos entre servicios.



Desacoplamiento con colas/eventos, para que no dependan uno del otro en tiempo real.



Retries con backoff: reintentos inteligentes sin saturar recursos.







Caso Práctico 1

El banco tiene un microservicio llamado auth-service desplegado en Kubernetes (EKS, GKE o on-prem). Este servicio:

- Valida usuarios
- Emite tokens JWT
- Consume una base de datos y Redis para sesión temporal

Dado que es crítico para operaciones, debe estar siempre disponible.







Caso Práctico 2

Un banco ofrece un portal web transaccional donde los clientes pueden revisar saldos, movimientos y realizar transferencias.

El frontend se comunica con una API REST interna para obtener los datos del cliente (/api/account/summary).

Problema:

Durante un despliegue, se introdujo una lógica de reintentos automáticos en el frontend si la API falla que colapso el sistema.







¿Cómo diseñar sistemas escalables y menos acoplados?



- Muchos compartimientos
- Poco espacio de trabajo (límite físico)
- Cuesta encontrar lo que necesito
- Muy probable tener muchas herramientas duplicadas







¿Cómo diseñar sistemas escalables y menos acoplados?



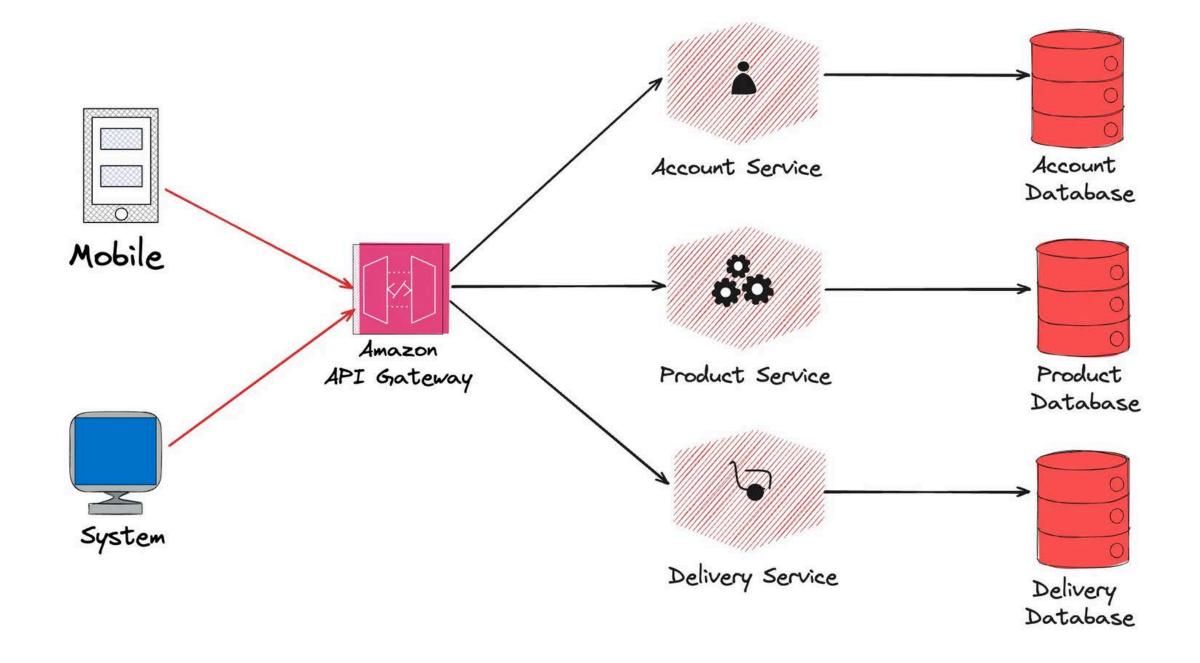
En software que es el símil a esto:

- Microservicios
- Serverless





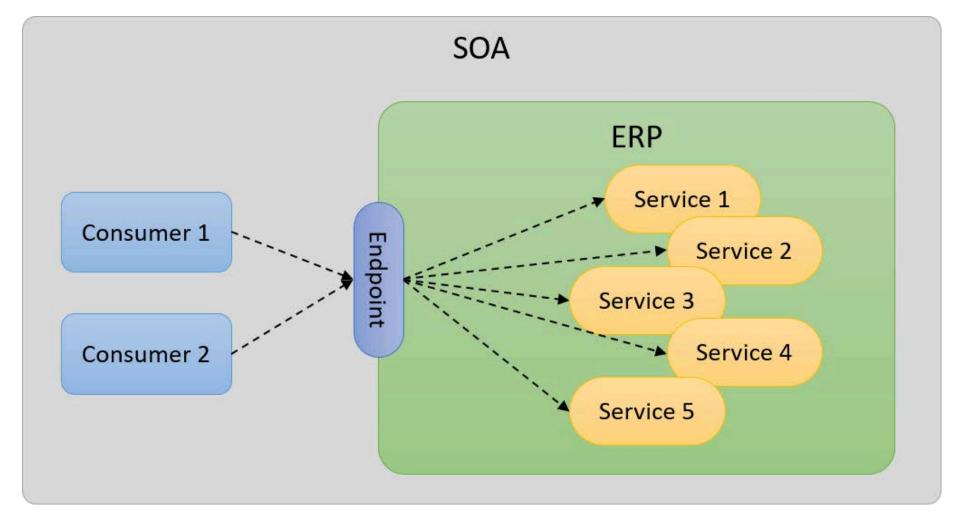


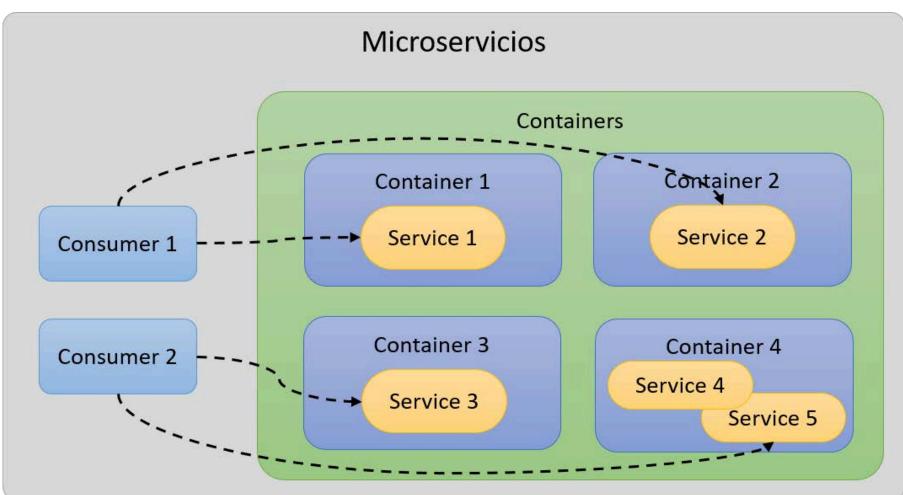














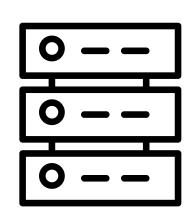




¿Cómo se conforma normalmente un Microservicio?



Interfaz



Backend



Base de datos

- Acotado
- Proposito claro







¿Cómo defino que microservicios modelar?

Criterios de negocio

Domain Driven Design
Event Storming
Bussiness Capability Mapping

Recursos disponibles

Criterios técnicos

Hexagonal Architecture
Clean Architecture
Service Mesh







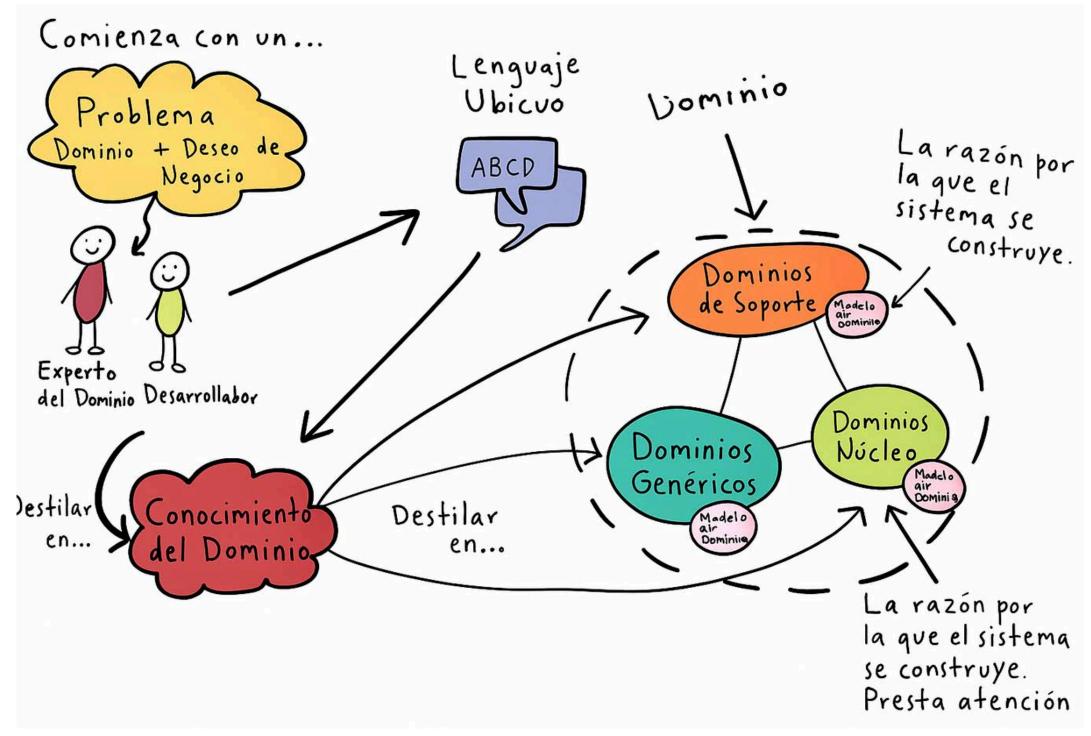
Criterios de negocio

- **Dominio funcional claro**: cada microservicio debe alinearse con una función específica del negocio (por ejemplo: facturación, gestión de inventario, atención al cliente).
- Independencia en la evolución del negocio: si una parte del negocio cambia con frecuencia o de forma autónoma, puede justificar un microservicio separado.
- **Diferentes prioridades de desarrollo**: algunas funcionalidades pueden requerir cambios rápidos o tener objetivos distintos (como innovación vs. estabilidad).









Bounded Contexts

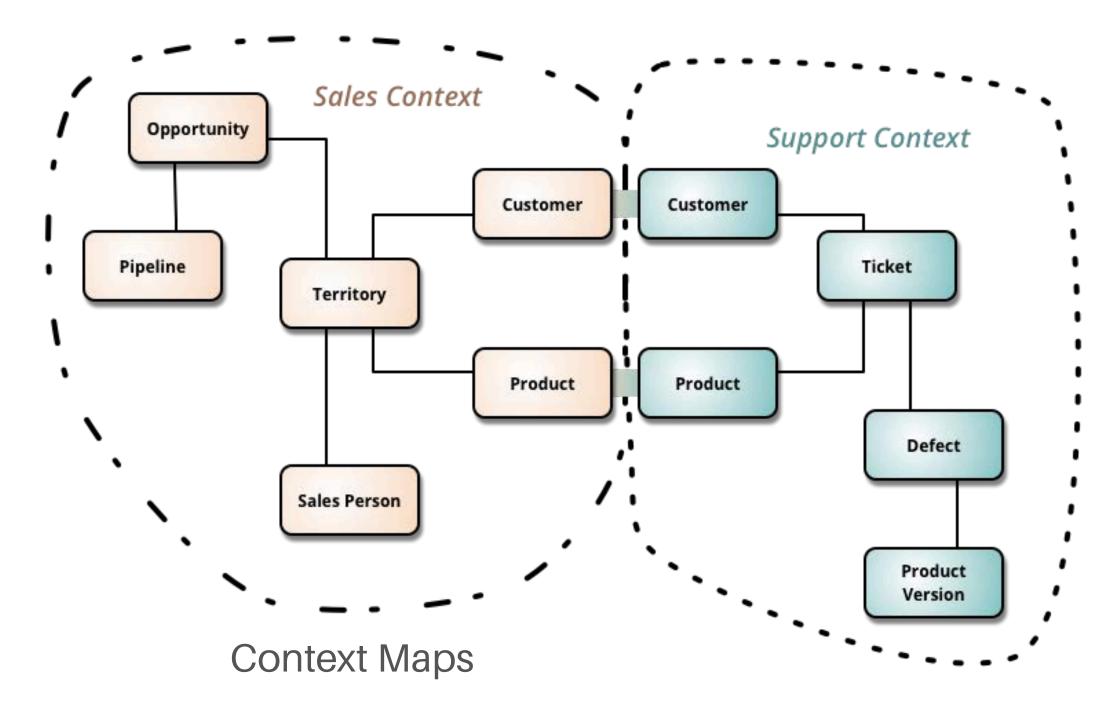
Aggregates y Entities

Ubiquitous Language









Bounded Contexts

- Entrevistas con expertos
- Listado de conceptos
- Ver que se traslapa conceptualmente







DDD Táctico: Entidades, Value Objects y Agregados

Entidades

```
class CuentaBancaria {
  constructor(readonly id: string, private saldo: number) {}

  depositar(monto: number) { this.saldo += monto; }

  retirar(monto: number) { if (this.saldo >= monto) this.saldo -= monto; }
}
```

Tienen identidad

Mutables







DDD Táctico: Entidades, Value Objects y Agregados

Value Objects

```
class Monto {
  constructor(readonly valor: number, readonly moneda: string) {
    if (valor < 0) throw new Error('El monto debe ser positivo');
  }
}</pre>
```

No tienen ID
Son comparables







DDD Táctico: Entidades, Value Objects y Agregados

Agregados

Conjunto de objetos que se pueden considerar uno para interactuar con operaciones y transacciones

Un cliente del banco







Caso Práctico

Una institución financiera necesita modernizar su plataforma de otorgamiento de préstamos. Actualmente, el sistema es monolítico y presenta dificultades para escalar y adaptarse a nuevas reglas de negocio.

Para abordar este problema, se plantea un rediseño basado en microservicios. Se identifican al menos dos Bounded Contexts clave:

Gestión de Clientes: Responsable de almacenar y administrar la información personal y de contacto de los clientes.

Evaluación de Créditos: Encargado de procesar solicitudes de préstamo, validando antecedentes financieros y tomando decisiones de aprobación.

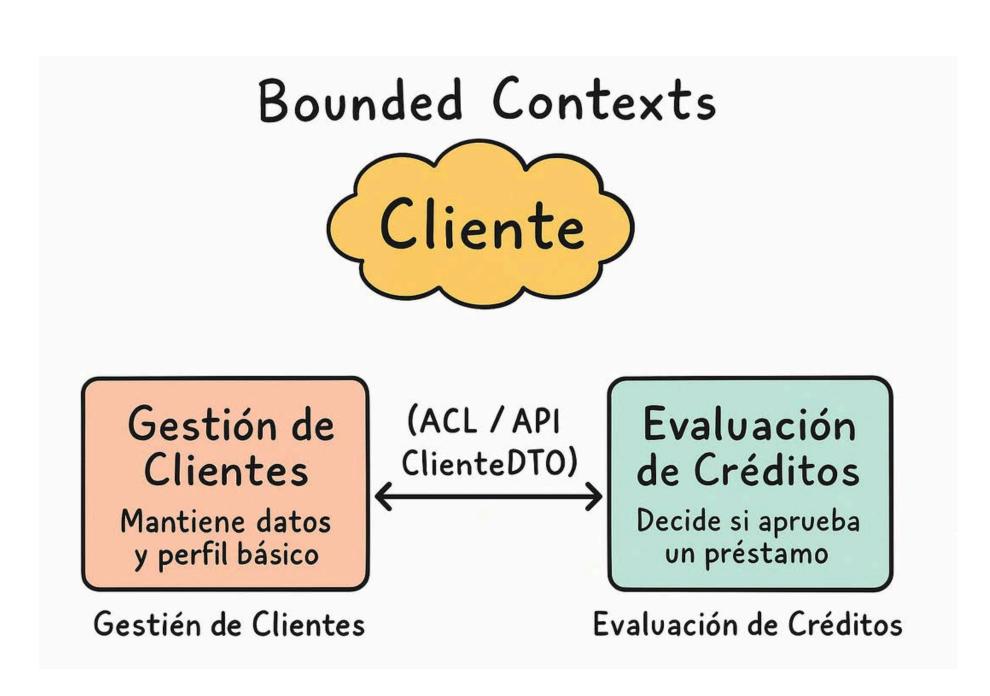
Ambos contextos comparten el concepto de "cliente", pero desde perspectivas distintas.







Caso Práctico



¿Cuáles serían mis candidatos a microservicios?

Gestión de Clientes

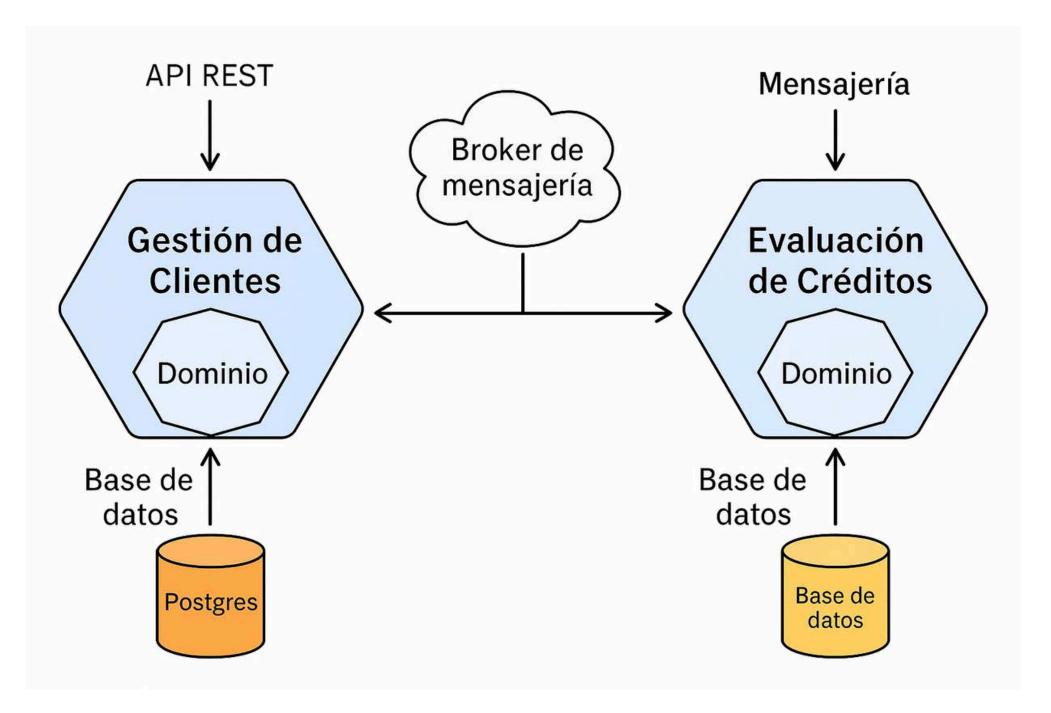
Evaluación de Créditos







Caso Práctico









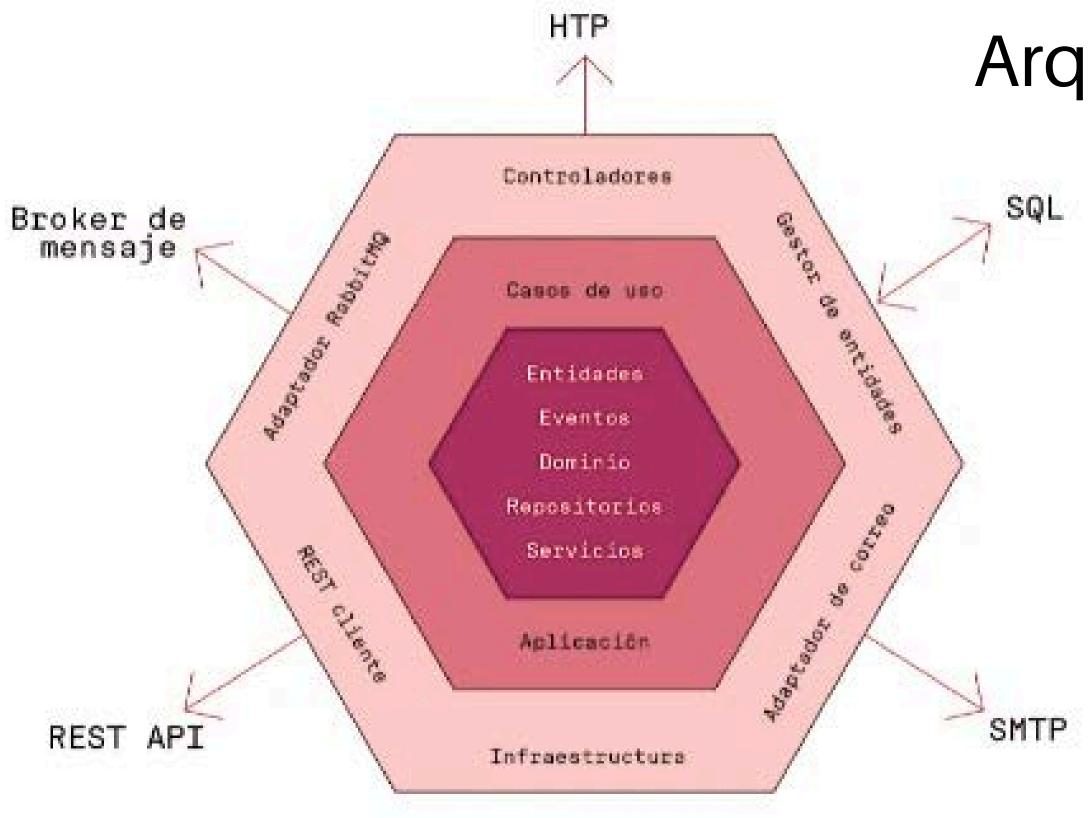
Criterios de técnicos

- Escalabilidad independiente: componentes que necesitan escalar de forma diferente (por ejemplo, el módulo de búsqueda puede requerir más recursos que el de autenticación).
- Aislamiento de fallos: evitar que un problema en un componente afecte a todo el sistema.
- Requerimientos tecnológicos distintos: por ejemplo, un servicio que necesita procesamiento en tiempo real puede estar mejor implementado en un lenguaje diferente o con una arquitectura distinta (como serverless).
- Límites naturales de datos: cuando una funcionalidad puede tener su propia base de datos sin necesidad de joins con otros dominios.









Arquitectura Hexagonal

Puertos y adaptadores

Dominio (Core)

Aplicación (casos de uso)







¿Cómo corre un código si no hay servidor?



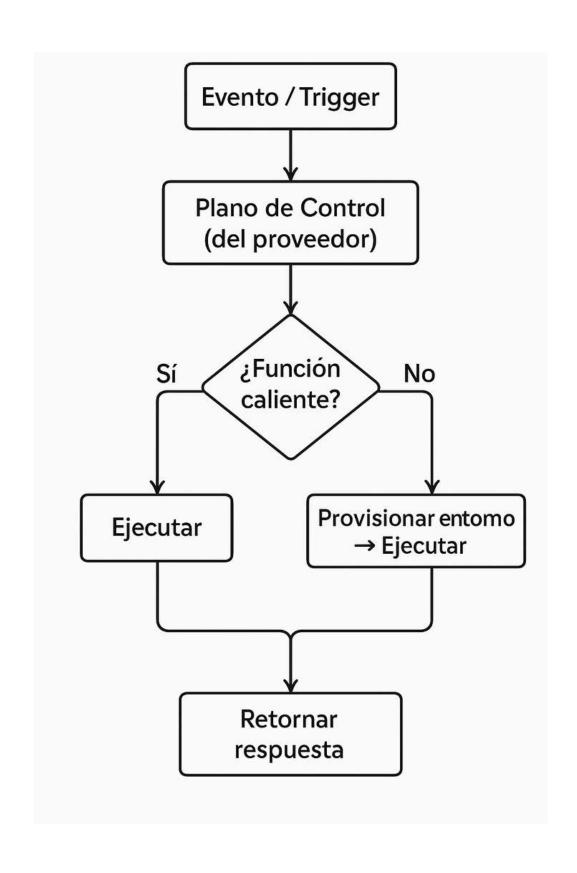
Sí lo hay!!!!!

Pero se disponibilizan por requerimiento









Las máquinas se encienden

Cold Start Warm













¿Qué debo considerar al diseñar?

Serverless Uso eficiente de recursos

Cold Start Friendly Event-driven

Ejecuciones rápidas Escalabilidad

Concurrencia Idempotencia







¿Qué debo considerar al diseñar?

Desacoplado Observabilidad

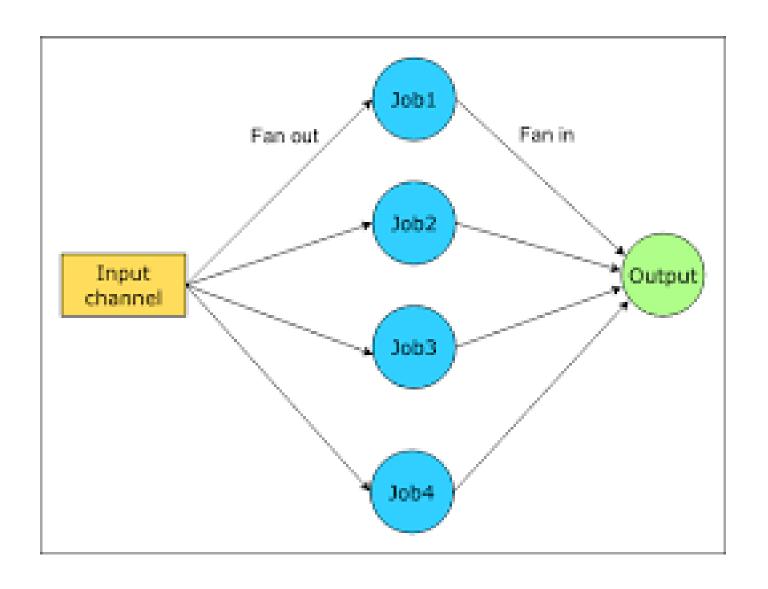
Seguridad mínimo acceso Reintentos



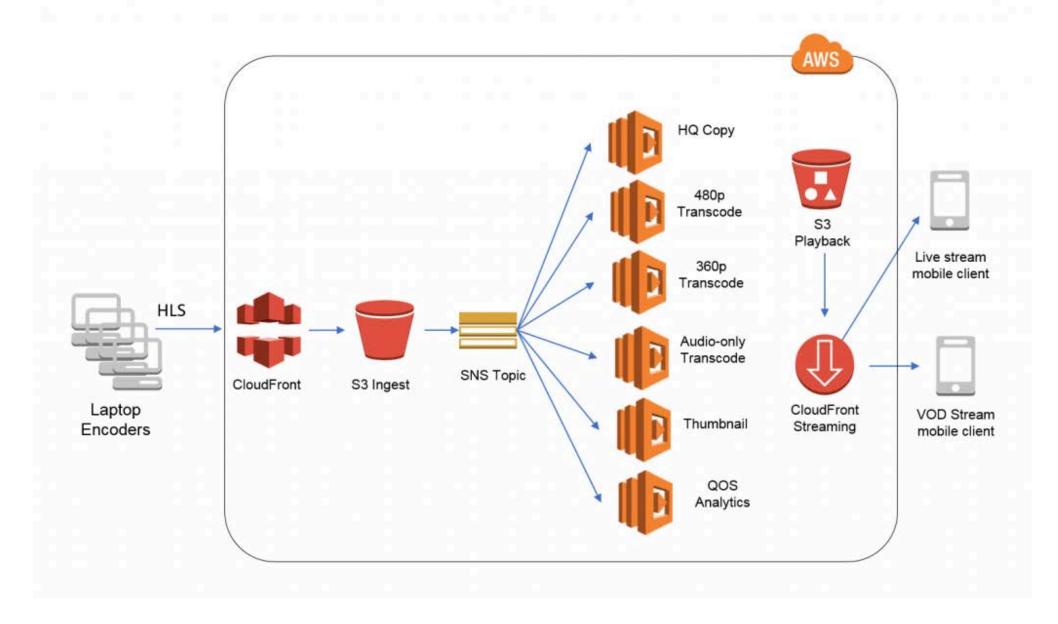




Fan In/Fan Out



Messenger / Subscriber









Caso Práctico

Evaluación Comercial de Clientes - ETL Diario (Serverless)

Contexto:

El banco necesita consolidar diariamente la información comercial de cada persona (ingresos, comportamiento financiero, deudas, etc.) desde múltiples fuentes externas e internas. Esta información se usará para analítica avanzada y futuras decisiones de crédito.







Caso Práctico

Consideraciones:

Fuentes de datos:

- Servicio_AFP
- Servicio_SII

Topicos Colas:

data_ready

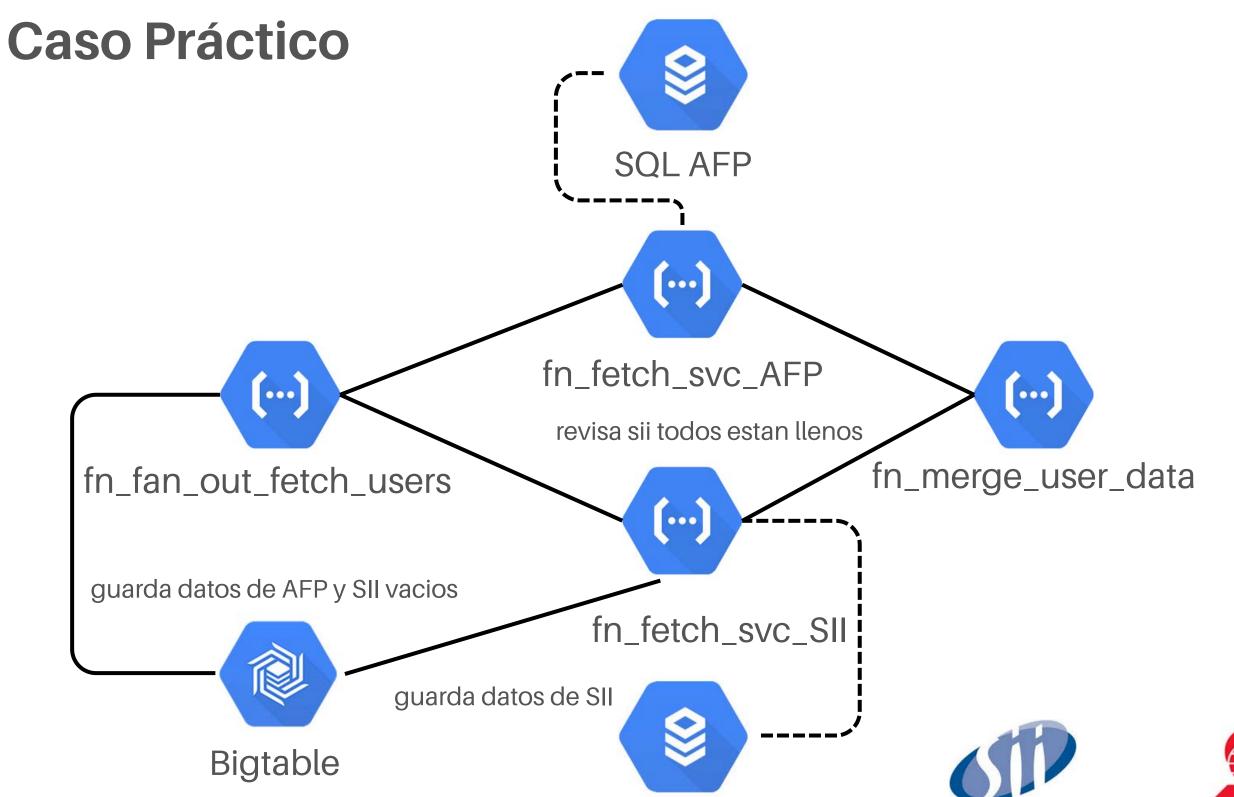
Información:

- Bigtable
 - Llave primaria (user_id_svc)









SQL SII

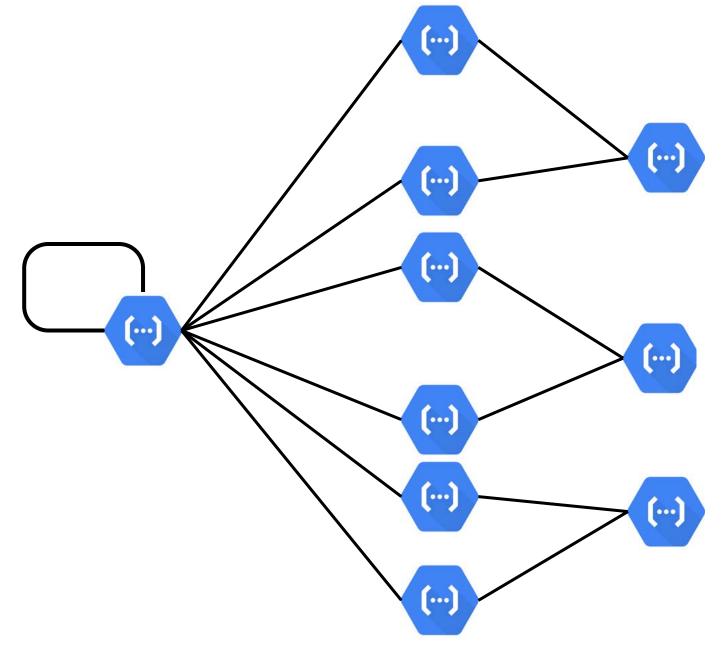




Group



Caso Práctico









Caso Práctico: Smart ATM

Sensores en ATM reportan datos (nivel de efectivo, errores, estado) y mandan la información via HTTP a la nube.

Se requiere alertar a las distintas áreas de mantenimiento de forma automática para mejorar la calidad de servicio al cliente.

¿Cómo lo harían? (veamos opciones y sus ventajas)







Event Driven Design

Caso Práctico: Smart ATM

¿Cómo lo harían? (veamos opciones y sus ventajas)

• Cron para chequear los errores **Batch o lote Eventos**Reactivo Proactivo

Multicloud, replica HA

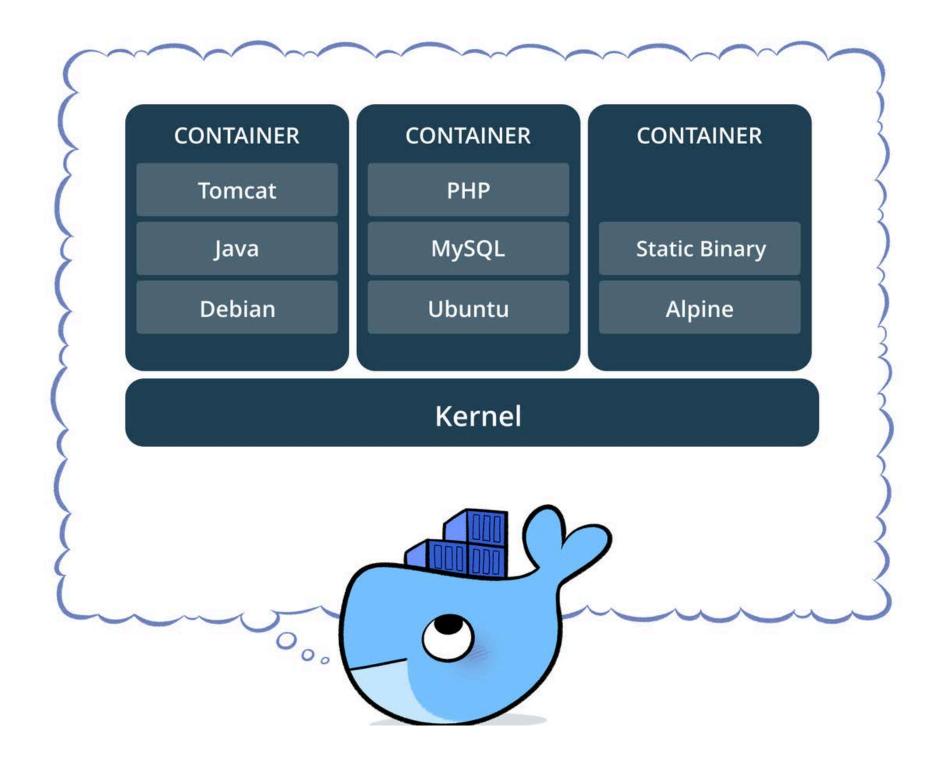
Computo Server Serverless
 1 instancia 1000 instancia

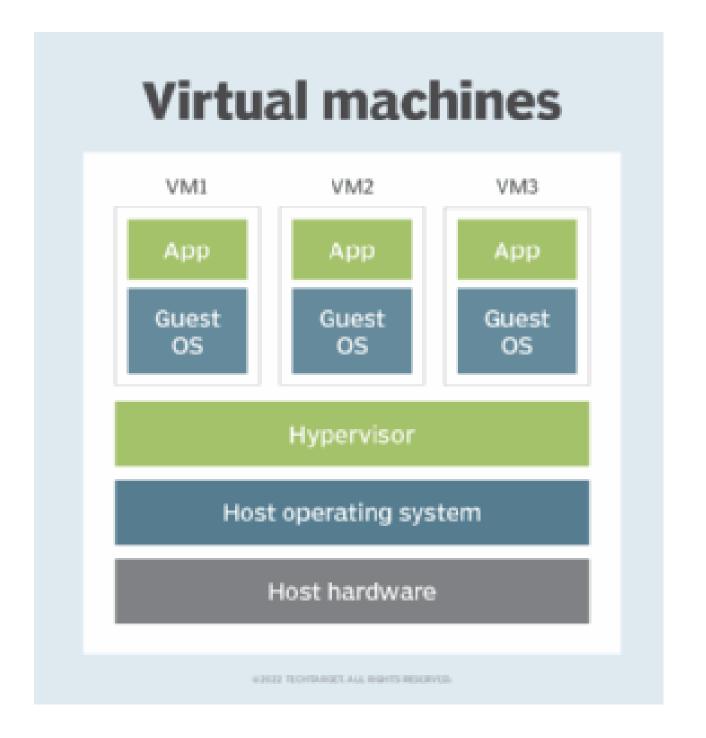






Contenedores





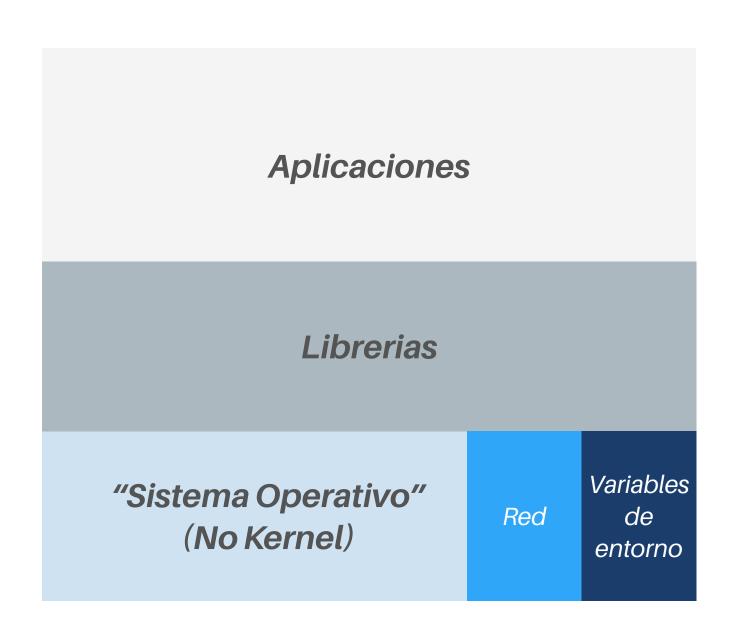






¿Qué son los contenedores?

Unidad funcional de software



No son:

- Máquinas Virtuales
- Sistemas Operativos

¿Para que sirven?







¿Qué son los contenedores?

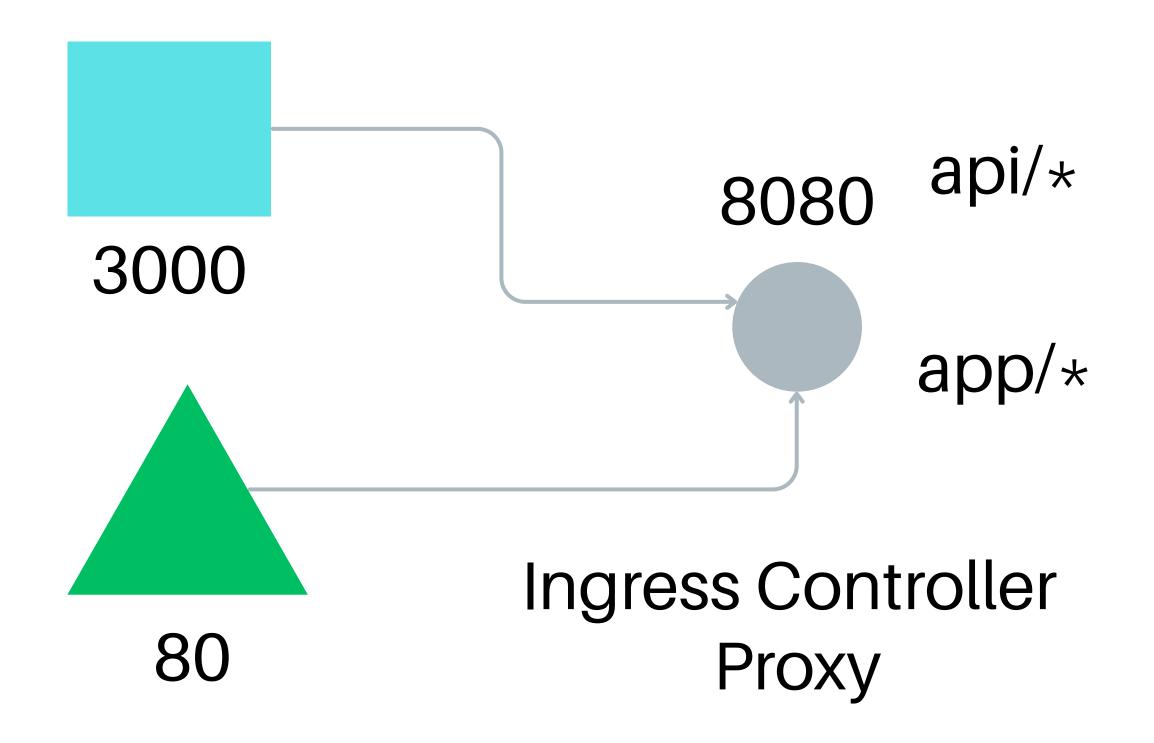
¿Para que sirven?

- Microservicio (descoplamiento: librerias, dependencias, red)
- Desarrollo (mismo ambiente) Debuguear















¿Qué son los contenedores?

Característica	Contenedor	Máquina Virtual
Kernel	Comparte el kernel del host	Tiene su propio kernel
Peso	Ligero (MBs)	Pesado (GBs)
Velocidad de inicio	Segundos	Minutos
Aislamiento	Aislamiento de procesos	Aislamiento completo (hardware sim)
Uso de recursos	Más eficiente	Más demandante







¿Qué es Docker?



- Herramienta que permite crear contenedore
- Funciona nativamente en Linux*
- Se puede usar en cualquier SO

¿Cómo instalar Docker?









Creando mi primer contenedor









¿Por qué usar contenedores?

- Portabilidad y consistencia
- Desacoplamiento
- Aislamiento ligero
- Escalabilidad y replicabilidad
- Ecosistema maduro

¿Tiene alguna desventaja?

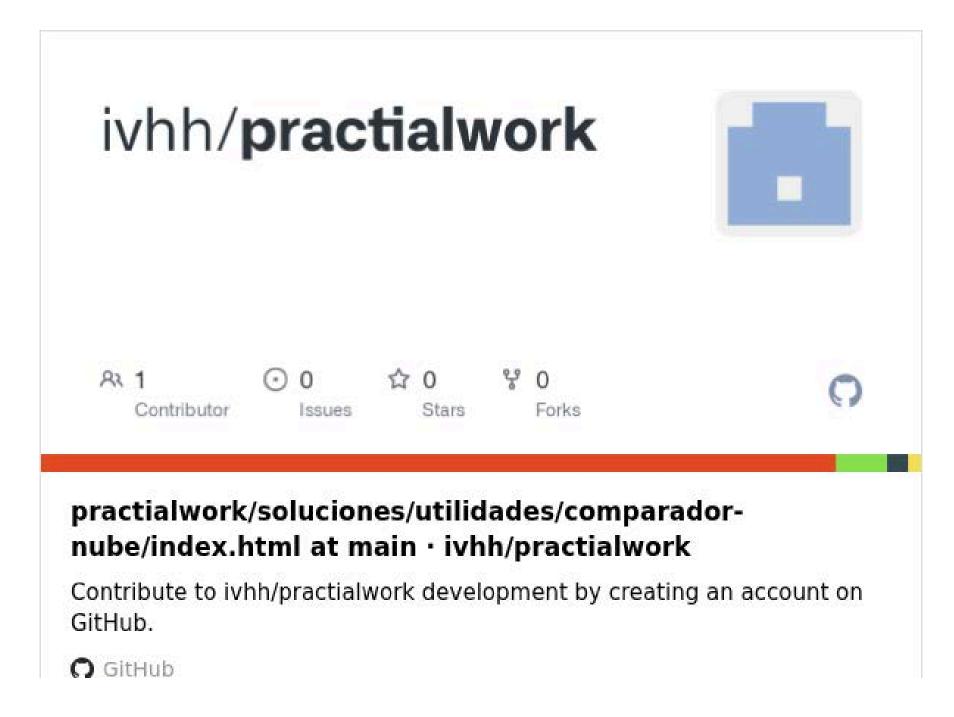








Servicios en la nube









Desafio práctico









Mini-lab 1: Crear una máquina virtual









Mini-lab 2: Base de datos gestionada

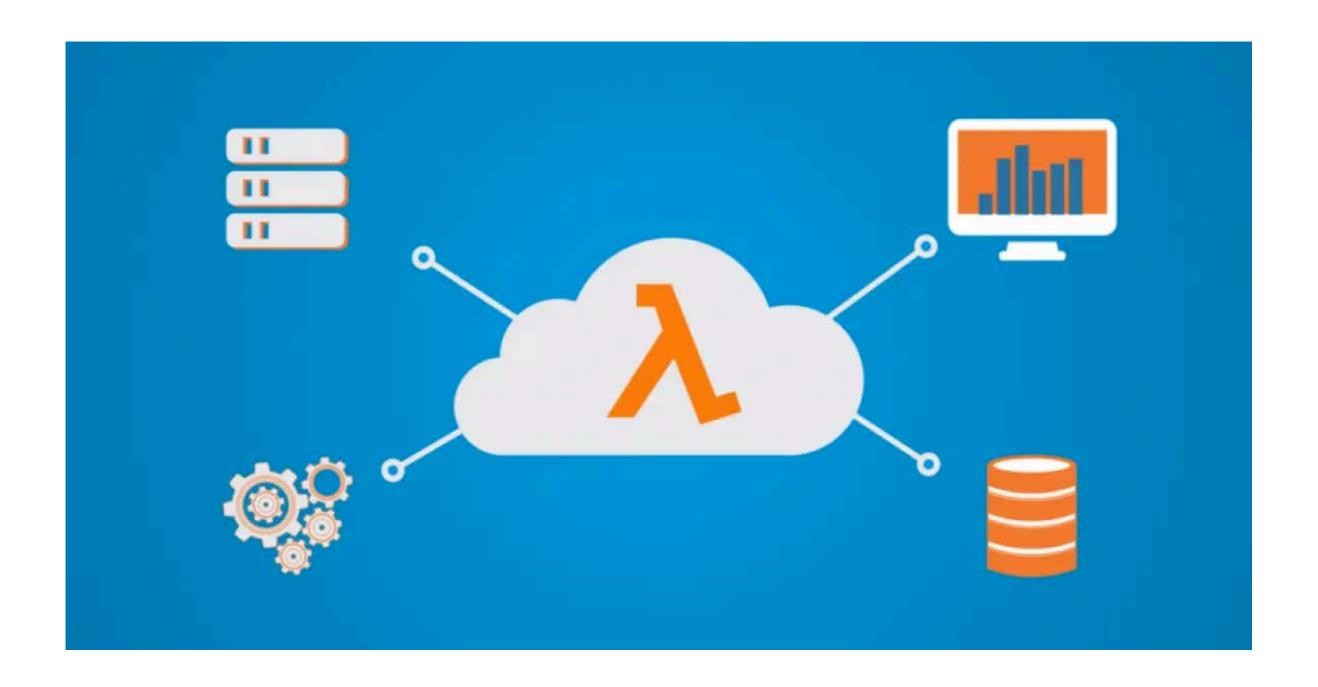








Mini-lab 3: Serverless function









Mini-lab 4: Desplegar contenedor

